

Relatório Técnico: Análise de Acidentes de Trânsito em Belo Horizonte

1. Identificação do Projeto e Dataset

Tema: Modelagem e Análise de Acidentes de Trânsito com Vítima em Belo Horizonte.

Autor: Mateus de Souza Rodrigues

Fonte dos Dados: Portal de Dados Abertos da Prefeitura de Belo Horizonte (BHTRANS).

Links dos Datasets:

- [Ocorrências de Acidentes](#)
- [Logradouros dos Acidentes](#)
- [Veículos Envolvidos](#)
- [Pessoas Envolvidas](#)

Link do Repositório: <https://github.com/MateusSRodrigues/TP-Banco-de-Dados>

2. Histórico do Projeto e Processo Produtivo


Durante o desenvolvimento deste trabalho, enfrentei uma série de desafios técnicos, especialmente na fase de ingestão e limpeza dos dados brutos usando o DuckDB. Os arquivos CSV da BHTRANS apresentaram um alto nível de ruído e inconsistências estruturais que exigiram soluções programáticas para não comprometerem a criação do banco de dados.

Os maiores gargalos enfrentados no processo produtivo foram:

- **Inconsistência de Datas:** A coluna de data e hora no dataset não seguia um padrão único. Havia registros no formato %d/%m/%Y %H:%M:%S e outros sem os segundos (%d/%m/%Y %H:%M). Precisei implementar a função `try_strptime` combinada com um `coalesce` no script de carga para evitar que o banco rejeitasse as linhas.
- **Problemas de Encoding e Colunas Fantasma:** Os arquivos utilizavam codificação ISO-8859-1 (e não UTF-8). Além disso, a função `read_csv_auto` do DuckDB falhava frequentemente porque o CSV continha vírgulas sobrando no final das linhas, criando colunas extras. Tive que forçar a leitura mapeando as colunas úteis e criando colunas de descarte (ex: `ignorar_1`, `ignorar_2`).
- **Chaves Estrangeiras e Ordem de Inserção:** A ordem de deleção (`DROP TABLE`) e inserção dos dados gerou conflitos devido às restrições de chaves estrangeiras. A solução adotada foi estruturar tabelas temporárias (staging) e utilizar o comando `ON CONFLICT DO NOTHING` para tratar chaves primárias duplicadas diretamente nos arquivos brutos.

3. Etapa 1: Projeto Conceitual (Modelo ER)

Nesta fase inicial, mapeei a realidade do trânsito de BH para abstrações de banco de dados. Utilizei a notação clássica de Peter Chen (entidades em retângulos e atributos em elipses) para construir o Diagrama Entidade-Relacionamento.



3.1 Entidades e Relacionamentos Principais


- **OCORRENCIA:** A entidade central (equivalente ao Boletim). Possui atributos como data, velocidade permitida, coordenadas e o indicador de fatalidade.
- **LOGRADOURO:** Guarda as informações geográficas (ruas, avenidas, bairros). Relaciona-se com a ocorrência através do losango "ocorre em" (cardinalidade N:M, já que uma rua tem vários acidentes e um acidente pode cruzar mais de uma rua).
- **VEICULO:** Entidade fraca em relação à ocorrência, pois um veículo sem o boletim perde o contexto. Guarda categoria, espécie e situação.
- **ENVOLVIDO:** Representa motoristas, passageiros ou pedestres. Tem atributos demográficos (idade, sexo) e situacionais (embriaguez, uso de cinto, severidade do ferimento).

3.2 Restrições de Integridade do Domínio

- A idade do envolvido não pode ser um número negativo, devendo estar idealmente em um range válido (filtrei entre 16 e 95 anos para condutores nas análises).
- O sexo deve assumir apenas domínio restrito ('M', 'F' ou 'O'/Não informado).
- As coordenadas X e Y precisam pertencer à zona UTM de Belo Horizonte (Sirgas 2000 fuso 23S).

4. Etapa 2: Modelo Relacional e Normalização

Fiz a tradução do modelo conceitual para o modelo relacional lógico, garantindo que o banco não sofresse com anomalias de atualização, inserção ou exclusão.



4.1 Processo de Normalização (Até a 3FN)

Na tabela de dados brutos fornecida pela prefeitura, as descrições de domínios vinham coladas nos códigos (ex: coluna cod_tempo junto com desc_tempo). Isso feria a Terceira Forma Normal (3FN), pois criava uma dependência transitiva onde um atributo não-chave dependia de outro não-chave.

Minha decisão de modelagem foi isolar todos esses domínios em **tabelas dimensionais auxiliares** (TIPO_ACIDENTE, TEMPO, PAVIMENTO, REGIONAL, BAIRRO, CATEGORIA_VEICULO, SEVERIDADE_ENVOLVIDO, etc). Dessa forma, a tabela fato BOLETINS guarda apenas os IDs numéricos (Foreign Keys). Se for necessário renomear a descrição de um tipo de asfalto no futuro, atualiza-se apenas uma linha na tabela de domínio correspondente.

Tabela Principal	Chave Primária (PK)	Chaves Estrangeiras (FK) Principais
BOLETINS	numero_boletim	tipo_acidente, cod_tempo, cod_pavimento
BOLETIM_LOGRADOUROS	(numero_boletim, seq_logradouros)	numero_boletim, num_logradouro
VEICULOS	(numero_boletim, seq_veic)	numero_boletim, cod_categ, cod_especie
ENVOLVIDOS	(numero_boletim, num_envolvido)	numero_boletim, cod_severidade

5. Etapa 3: Implementação em SQL (DDL e Carga)

Utilizei o **DuckDB** pelo seu excelente desempenho analítico e facilidade de lidar com múltiplos arquivos CSV simultaneamente. O script Python (bd.py) foi criado para recriar as tabelas dinamicamente e orquestrar a carga de dados.

5.1 Limpeza e Tratamento de Dados (Anomalias Encontradas)

Durante a análise exploratória prévia à carga definitiva, identifiquei problemas graves na qualidade dos dados fornecidos:

- **O Atributo VALOR_UPS (Severidade Geral):** Percebi que possuía preenchimento inconsistente e muito ruído. Substituí o seu uso analítico cruzando o indicador binário de fatalidade com o `cod_severidade = 2` da tabela de pessoas envolvidas, gerando maior fidelidade.
- **O Atributo local_sinalizado:** O preenchimento estava massivamente viciado com o valor "Não" ou era nulo. Concluí que deve haver um padrão de ignorar esse campo na pressa do preenchimento dos boletins. A variância quase nula me forçou a não utilizá-lo para inferências estatísticas de segurança viária.

O preenchimento das tabelas dimensionais foi feito lendo as tabelas de *staging* (tabelas temporárias do arquivo csv) usando a função agregadora `MAX()` nas descrições e um agrupamento (`GROUP BY`) pelos códigos numéricos. Isso impediu erros no momento da carga, caso os CSVs apresentassem descrições ligeiramente diferentes para o mesmo ID numérico ao longo dos anos.

6. Etapa 4: Consultas e Análise Exploratória (EDA)


Abaixo listo as perguntas investigativas formuladas, as queries desenvolvidas e a discussão crítica dos resultados de negócio alcançados.

Pergunta 1: Quais vias concentram o maior número de acidentes e como a letalidade varia entre elas?

Esta consulta precisou de uma CTE (Common Table Expression) avançada para pré-calcular o volume total de pessoas acidentadas e de vítimas fatais por boletim, e depois fazer múltiplos `JOINS` ligando o Boletim aos Logradouros.

SQL

```
WITH pessoas_boletim AS (  
    SELECT  
        numero_boletim,  
        COUNT(num_envolvido) AS qtd_pessoas_total,  
        SUM(CASE WHEN cod_severidade = 2 THEN 1 ELSE 0 END) AS  
qtd_vitimas_fatais  
    FROM ENVOLVIDOS  
    GROUP BY numero_boletim  
)  
,  
vias AS (  
    SELECT  
        l.nome_logradouro,  
        COUNT(DISTINCT b.numero_boletim) AS total_acidentes,  
        SUM(p.qtd_pessoas_total) AS total_pessoas_envolvidas,  
        SUM(p.qtd_vitimas_fatais) AS total_vitimas_fatais  
    FROM BOLETINS b  
    JOIN BOLETIM_LOGRADOUROS bl ON b.numero_boletim =  
bl.numero_boletim  
    JOIN LOGRADOURO l ON bl.num_logradouro = l.num_logradouro  
    LEFT JOIN pessoas_boletim p ON b.numero_boletim =  
p.numero_boletim  
    WHERE l.nome_logradouro IS NOT NULL  
    GROUP BY l.nome_logradouro  
)  
SELECT  
    nome_logradouro,  
    total_acidentes,  
    total_pessoas_envolvidas,  
    total_vitimas_fatais,  
    ROUND((total_vitimas_fatais * 100.0 /  
NULLIF(total_pessoas_envolvidas, 0)), 2) AS taxa_letalidade_pct  
FROM vias  
WHERE total_acidentes >= 50  
ORDER BY total_acidentes DESC  
LIMIT 10;
```




Discussão Crítica: Descobri que o volume absoluto de acidentes não dita necessariamente a letalidade. O Anel Rodoviário Celso Mello Azevedo é um extremo outlier no banco: além de ter quase 8.000 ocorrências, a letalidade bate impressionantes 1,65% (quase 300 mortos). Já a Avenida do Contorno, apesar do volume alto (4º lugar), tem a menor letalidade do topo (0,21%). Isso acontece porque o Anel tem dinâmica de rodovia pesada, enquanto a Av. do Contorno resulta em batidas leves devido aos engarrafamentos contínuos.

Pergunta 2: Qual é o perfil demográfico (sexo e idade média) dos condutores envolvidos em acidentes?

```
SQL
SELECT
    sexo,
    COUNT(DISTINCT numero_boletim || num_envolvido) AS
total_condutores_envolvidos,
    ROUND(AVG(idade), 1) AS idade_media
FROM ENVOLVIDOS
WHERE condutor = 'S'
    AND idade IS NOT NULL
    AND idade BETWEEN 16 AND 95
    AND sexo IN ('M', 'F')
GROUP BY sexo
HAVING COUNT(DISTINCT numero_boletim || num_envolvido) > 1000
ORDER BY total_condutores_envolvidos DESC;
```

Proporção de Condutores Envolvidos em Acidentes por Sexo
(e Idade Média)



Discussão Crítica: Notei uma disparidade gigantesca. Os homens respondem por 83% dos condutores acidentados, contra apenas 17% de mulheres. A idade média é quase igual (aprox. 37 anos). No mundo real, além das questões comportamentais (agressividade no trânsito), isso valida e justifica matematicamente os modelos de precificação de apólices de seguro (onde homens pagam mais caro) e reflete o fato de que a maioria dos motoristas profissionais (caminhoneiros, motoristas de app, motoboys) são do sexo masculino, aumentando drasticamente a exposição diária ao risco.

Pergunta 3: Como o horário do dia afeta a proporção de letalidade nos acidentes?


```
SQL
WITH horas AS (
    SELECT
        CAST(EXTRACT(HOUR FROM b.data_hora_boletim) AS INTEGER) AS
hora_dia,
        COUNT(e.num_envolvido) AS total_pessoas,
        SUM(CASE WHEN e.cod_severidade = 2 THEN 1 ELSE 0 END) AS
obitos
    FROM BOLETINS b
    JOIN ENVOLVIDOS e ON b.numero_boletim = e.numero_boletim
    WHERE b.data_hora_boletim IS NOT NULL
    GROUP BY EXTRACT(HOUR FROM b.data_hora_boletim)
)
SELECT
```



```

hora_dia,
total_pessoas,
obitos,
ROUND((obitos * 1000.0 / NULLIF(total_pessoas, 0)), 2) AS
letalidade_por_mil
FROM horas
ORDER BY hora_dia;

```



Discussão Crítica (O Paradoxo do Trânsito): Encontrei um comportamento perfeitamente inversamente proporcional. Em horários de pico comercial (7h-9h e 17h-19h), o volume de batidas atinge o máximo, mas a taxa de mortes fica em seu nível mais baixo (cerca de 2 mortos a cada 1.000 envolvidos). Porém, na madrugada (01:00 às 05:00), ocorre uma anomalia: o volume de acidentes cai drasticamente, mas o risco individual explode, batendo picos de quase 30 óbitos a cada 1.000 vítimas. Vias vazias incentivam excesso de velocidade, mistura com álcool e desrespeito à sinalização intermitente.

7. Conclusão

A execução deste trabalho foi fundamental para conectar a teoria de banco de dados com problemas difíceis e reais do processamento de dados brutos. Aprendi na prática que modelar o esquema relacional no papel (Modelo ER) é muito diferente de receber arquivos reais e lidar com sujeira, campos nulos, codificações problemáticas e anomalias sistêmicas de preenchimento. O uso de CTEs no SQL e do agrupamento no Python me permitiu construir visualizações claras sobre a base de dados em DuckDB.

A principal limitação enfrentada foi a ausência de chaves únicas 100% confiáveis em algumas

tabelas abertas da BHTRANS, o que me forçou a criar lógicas defensivas de importação (como `DISTINCT` e concatenações provisórias de ID). Contudo, consegui isolar as dimensões analíticas em tabelas estruturadas até a Terceira Forma Normal, finalizando o projeto com sucesso e extraindo insights valiosos que servem para o planejamento de políticas públicas de segurança viária em Belo Horizonte.